

우제율 Jae-Yul Woo

Embedded & Firmware · AI-Native Development · DevOps Automation

파운드리 설계 지원 현장에서 사내 LLM API로 EDA 툴 실행 자동화, 설계 파라미터 값 수집, 툴 로그 파싱·저장을 하는 엔지니어입니다. 새로운 도메인에 대해 업무를 시작하게 되면 먼저 AI로 도서관과 지식 지도를 만들고, 그 위에서 프로그램을 짓습니다. Claude Code(계획·리뷰), Codex CLI(교차 검증), Antigravity(병렬 실행)를 역할을 나눠 함께 쓰며, 결과는 hook·CI·정책으로 검증합니다. 이 문서는 문제 → 도구 → 결과물 순서로 대표 사례 5가지를 정리한 것입니다.



dkdlqoddi@gmail.com github.com/dkdlqoddi dkdlqoddi.github.io

2026-09-27

AI AGENT ORCHESTRATION

2026-04 ~ 2026-09 · 2026-09-22 로컬 전수 집계 기준

5개월간의 산출 지표

총 컨텍스트 처리량

~114억 토큰

Claude Code 101.0억 · Antigravity 9.3억 · Codex CLI 3.6억 (11,401,278,027)

순수 생성 및 추론량

~7,251만 토큰

코드 작성, 추론, 회귀 디버깅 산출물 (72,513,989)

46개

신규 GitHub 저장소

1,800+

고유 커밋 (중복 클론 제외)

20+

셀프호스팅 CI 러너

7편

팀 세미나 발표

- 01 모르는 도메인을 도서관과 지식 지도로 만들기
- 03 에이전트가 사내 서버를 안전하게 쓰게 하는 인프라
- 05 확산: 팀 세미나 7편과 발표 사이트

- 02 그 지식 위에 세운 프로그램: GAIA 2.0
- 04 개발 방법 자체를 도구로: 하네스와 오케스트레이터
- 06 도구별 역할, 운영 방식, 공개 산출물, 경력 요약

01 모르는 도메인을 도서관과 지식 지도로 만들기

사내 LLM 위키 · 논문 지식 베이스 · 사내 의미 검색 · 3계층 문서와 결정 기록

문제

반도체 설계 사인오프 흐름, EDA 도구, 팀의 SOP처럼 제가 모르는 도메인 지식이 코드보다 먼저 필요했습니다. 자료는 흩어져 있고, 에이전트에게 매번 다시 설명하면 컨텍스트가 낭비됩니다.

도구와 접근

원문(raw)은 불변으로 보존하고 Claude Code 스킬이 출처·개체·개념·주제 위키 마크다운을 유지합니다. Next.js 앱이 GraphRAG와 BM25 하이브리드 검색을 제공하고, 헤드리스 인제스트에는 권한 deny 목록을 걸어 문서 속 프롬프트 인젝션이 소스를 수정하지 못하게 했습니다. 코드베이스 쪽은 규칙·지도·명세 3계층 문서와 한 줄짜리 결정 기록으로 지식 지도를 유지합니다.

결과물

- 사내 LLM 위키(커밋 120건, Next.js 16 + pnpm)와 개인용 custom-llm-wiki(Claude Code 스킬 /wiki-save · /wiki-ask, BM25 + e5-small 임베딩 하이브리드 검색, RAG 채팅).
- 논문 PDF를 메타·요약·개념 노트로 양방향 추적하는 논문 지식 베이스(paper-review), 사내 LLM(Gemma 4)과 BGE-M3 임베딩·자체 호스팅 벡터 DB 기반 의미 검색 설계(cds-librarian).
- 10명이 동시에 Claude Code로 개발할 저장소에서 ADR 66건·요구사항 137건을 3계층 문서로, 다시 결정 기록 표로 이관해 다시 묻지 않는 협업 체계 구축.

120

LLM 위키 커밋

66 + 137

이관한 ADR·요구사항 건수

GraphRAG + BM25

하이브리드 검색

deny 목록

헤드리스 인제스트 권한 제한

02 그 지식 위에 세운 프로그램: GAIA 2.0

반도체 설계 사인오프 진행 추적 폴스택 대시보드 (2026-06 ~ 현재)

문제

설계 과제의 Task·Checklist 일정과 Run 검증 결과가 엑셀과 메일에 흩어져 있어 사인오프 진행을 한눈에 볼 수 없었습니다. 도메인 규칙이 자주 바뀌어 요구사항이 130건 넘게 쌓였습니다.

도구와 접근

Claude Code가 요구사항 인터뷰 → 명세 → 구현 → 변경 분석 → 머지 전 퀴즈까지 수행하는 하네스로 개발했습니다. 검증은 Playwright e2e·vitest·husky 게이트와 셀프호스팅 러너 2대 병렬 CI가 맡고, 사람은 PR 리뷰와 머지만 합니다.

결과물

- Next.js 16 App Router 단일 앱, Prisma + PostgreSQL 모델 23개, Route Handler 41개, 모듈 19개, 커밋 850건 이상.
- 마일스톤별 Score·추세 대시보드, 인라인 일정 편집 Task Gantt, SOP 체크 이행 화면, Run 파생 트리, react-konva floorplan 편집기, XLSX 적재·내보내기 SOP 워크스페이스, Domain 리포트 이메일 발송, LangGraph 어시스턴트.
- 같은 방식으로 넷리스트 파싱·DB 적재 파이프라인(netlist-agent)과 LangGraph 로그 분석 플로우를 구축. 릴리스·DB 마이그레이션 절차와 러너 운영 노하우는 결정 기록으로 축적.

850+

커밋

23 / 41 / 19

모델 · API · 모듈

7 라우트

Dashboard부터 Summary Report까지

e2e + CI

Playwright · 러너 2대 병렬

03

에이전트가 사내 서버를 안전하게 쓰게 하는 인프라

정책 기반 MCP 서버 · LLM 게이트웨이 API 서버 · Agent Skill 허브 · 이메일 아카이빙 (2026-07 ~ 09)

문제

OpenCode·Claude Code·Codex가 공용 원격 서버의 파일과 명령, DB, 내부 API를 써야 하지만, 무엇이든 열려 주면 위험하고 폐쇄망이라 외부 서비스도 쓸 수 없습니다.

도구와 접근

디렉터리별 read/write/command 정책으로 접근을 기본 거부하고 관리자가 등록한 것만 여는 MCP 서버를 Python으로 만들고, 사내 LLM 게이트웨이 프록시·MCP REST 릴레이·투명 MCP 프로토콜 프록시를 FastAPI 서버 하나에 담았습니다. 테스트는 소켓 없는 mock으로 폐쇄망 밖에서도 돕니다.

결과물

- MCP 서버 툴 17개(파일·명령·DB 질의·내부 API·LangGraph 파일 분석·정책 조회), 폐쇄망 pip 미러 배포 절차.
- OpenCode 호환 Agent Skill 공유 허브(커밋 108건): Node.js 22 + SQLite, 릴리스 불변성(버전·ZIP·체크섬), 감사 로그, ZIP 경로 순회 검증, Docker + nginx.
- 사내 이메일 아카이빙 플랫폼(변환·수집·검색, 서킷 브레이커·중단 복구 클라이언트), fail-closed SAML 랜딩 페이지.

17

MCP 툴

3 in 1

LLM 프록시 · REST 릴레이 ·
MCP 프록시

108

스킬 허브 커밋

기본 거부

디렉터리 정책 · 감사 로그

04

개발 방법 자체를 도구로: 하네스와 오케스트레이터

dev-env-blindspot · 2-하네스 스왑 · cheap-agent · custom-llm-api · 모델 A/B 벤치마크 (공개)

문제

에이전트는 자기가 모르는 것을 모른 채 코드를 쓰고, 같은 질문을 세션마다 다시 하며, 강한 모델을 모든 단계에 쓰면 토큰이 과합니다.

도구와 접근

코드를 쓰기 전에 모르는 것을 결정 가능한 질문으로 바꾸는 blindspot-pass 스킴과 읽기 전용 codebase-scanner 에이전트, 세션 시작 hook, append-only 결정 기록을 서버모듈 한 줄로 설치하는 하네스를 만들었습니다. 판단은 Opus/Fable xhigh, 병렬 실행은 Gemini Flash에 배치했습니다.

결과물

- dev-env-blindspot(공개, 커밋 98건): 15개 이상 프로젝트 적용. 풀 버전의 토큰·시간·사용자 턴 비용을 실측한 뒤 lite로 축소, Claude Code가 계획·리뷰하고 Antigraity가 스왑 실행하는 claude-antigravity-cowork 브랜치 운영.
- cheap-agent v0.4.1: 구독 중인 CLI의 headless 모드를 실행 엔진으로 재활용하는 자기학습 오케스트레이터(의존성 0, 파일 기반 IPC, best-of-N-세션 재개·비용 상한 등 19개 토글, GitHub Actions CI). custom-llm-api: Antigraity CLI를 API 키 없이 OpenAI 호환 API로 노출. skill-verifier: 스킴 정적 검사 + LLM 리뷰.
- 자율 개발 스택(R14-V2): 이슈 → 스펙 → 구현 → 검증 → 리뷰 → 출하를 서버에이전트가 수행하고 사람은 PR 머지만. 같은 프롬프트 시퀀스로 Next.js 앱을 구축해 Opus와 Fable을 비교한 벤치마크 공개.

15+

하네스 적용 프로젝트

19

cheap-agent 기능 토글

2-하네스

Claude Code 계획 ·
Antigravity 실행

공개

GitHub 저장소 4종 이상

문제

혼자 빨라지는 것보다 팀이 같은 방법을 쓰는 것이 어렵습니다. 프롬프트 요령이 아니라 하네스가 결과의 폭을 조이는 원리를 눈으로 보여 줘야 했습니다.

도구와 접근

Reveal.js 기반 정적 발표 사이트를 빌드 없이 구축하고, 덩마다 애니메이션 다이어그램과 실습(OpenCode serve API 호출, EDA MCP 연동, Antigravity 실습)을 넣었습니다. 사실 서술은 출처를 달아 검증했고, Playwright 회귀 검증(탐색·목차·모바일·오프라인·PDF)을 스크립트로 자동화했습니다.

결과물

- 설계 AX 전환(07-31) · 안전한 AI 설계 자동화 아키텍처(08-03) · Python Automation: DX vs AX(08-19, 1부) · AI Agent Skills Philosophy(08-19, 2부) · 나만의 돌쇠 AI 만들기(09-01) · AI, 한 걸음 더(09-20) · 내 자료가 이해가 되는 순간: NotebookLM(09-21).
- 같은 사이트에 웹 이력서와 이 포트폴리오를 통합 배포.

7편

발표 자료

2부작

팀 세미나 (17장 + 28장)

0 빌드

정적 HTML · CDN 의존성 없음

Playwright

브라우저 회귀 검증

도구별 역할과 운영 방식 HOW THE TOOLS ARE USED

Claude Code	기본 세션(Fable 5.1, 1M 컨텍스트, effort max, 서브에이전트 Opus). 계획·설계·리뷰·머지 게이트처럼 판단이 필요한 자리. 공식 플러그인 9종(frontend-design, code-review, skill-creator, code-simplifier, playwright, claude-md-management, typescript-lsp, feature-dev, firecrawl)과 claude-mem. 셀프호스팅 러너에서 <code>claude -p</code> 헤더리스 실행. 누적 101.0억 토큰.
Codex CLI	같은 스펙을 다른 모델로 다시 구현·검증하는 교차 검증과 Codex용 하네스 브랜치 운영(2026-07 ~, 세션 580건 이상). 누적 3.6억 토큰.
Antigravity	Gemini Flash로 워커·체커 서브에이전트를 대량 병렬 실행하는 스웜 엔진(대화 500건 이상). Antigravity 전용 규칙·스킬·에이전트 파일과 설치 스크립트 유지. 누적 9.3억 토큰.
OpenCode · MCP	사내 표준 에이전트 클라이언트. 정책 기반 MCP 서버, EDA 벤더 MCP 3종, Agent Skill 허브와 연결.
검증 게이트	토큰은 판단에만 쓰고 검사·실행은 CPU에 맡깁니다. hook(세션 시작 규칙 주입·위험 명령 차단), husky, Playwright e2e, vitest, 셀프호스팅 GitHub Actions 러너 20여 개, PR 리뷰 머지 게이트, append-only 결정 기록.
비용 관리	모델 배치 원칙(판단 Opus/Fable xhigh, 탐색 Sonnet/Haiku, 병렬 실행 Gemini Flash), 풀 하네스 비용 실측 후 lite 축소, cheap-agent의 비용 상한·저가 planner 분리, 세 도구 사용량 전수 집계 스크립트 공개.

dev-env-blindspot 에이전트 공용 개발 하네스 (커밋 98건) github.com/dkdlqoddi/dev-env-blindspot	발표 사이트 세미나 7편 · 웹 이력서 · 포트폴리오 dkdlqoddi.github.io
jaeyul-woo-resume 이력서 원본 · 토큰 집계 스크립트 · 결정 기록 github.com/dkdlqoddi/jaeyul-woo-resume	모델 A/B 벤치마크 benchmark-nextjs-opus · benchmark-nextjs-fable · benchmark-result github.com/dkdlqoddi/benchmark-result
document-parser · netlist-agent Antigravity 스웜으로 구축한 파서·파이프라인 (공개) github.com/dkdlqoddi/netlist-agent	Weight-Changable-Model 학부 연구 논문 코드 (2021) github.com/dkdlqoddi/Weight-Changable-Model

사내 프로젝트(GAIA 2.0, MCP 서버, API 서버, LLM 위키, 스킬 허브 등)와 cheap-agent-custom-llm-api-skill-verifier는 비공개 저장소이며, 요청 시 구조와 문서를 설명드릴 수 있습니다.

경력 · 학력 요약 BACKGROUND

- **삼성전자 파운드리사업부 고객디자인지원팀 · 임베디드 소프트웨어 엔지니어 (2022.03 – 현재):** ARM Cortex-A/M 포팅, Linux 디바이스 드라이버, Trace32 원격 보드 무인 디버깅 시스템, 온프레미스 설계 데이터 웹 뷰어, Docker·Jenkins·GitHub Actions·Coverity·Checkpatch CI/CD. 현재 사내 LLM API 기반 EDA 톨 실행 자동화·설계 파라미터 값 수집·툴 로그 파싱·저장 등 반도체 설계 자동화, 2026년 AI 에이전트 기반 개발 전환과 사내 AI 인프라 구축.
- **SEC 연구소 시스템개발팀 · 소프트웨어 개발자 (2018.01 – 2019.06):** GNU Radio + CPython SDR 실시간 신호처리, 레거시 C 모듈 C-API 결합, 전국 분산 서버·안테나 원격 제어 자동화.
- **Rebellions REBEL Quad(4칩렛 NPU) RTOS·디바이스 드라이버 개발 참여,** Jetson 오프라인 온디바이스 에이전트, Isaac Sim + ROS 2 로봇 시뮬레이션 환경.
- **성균관대학교 반도체시스템공학 학사 (2014 – 2022):** IRIS Lab 학부 연구생(지도교수 고종환, 2020.03 – 2022.02), 논문 *A Proposal for a Weight Changeable Model corresponds to Network Packet Errors*.